

Ce rapport présente une architecture data complète, pensée pour une soutenance solide et une exploitation locale proche d'un déploiement de production. Le projet couvre l'ingestion multi-sources, la normalisation, les datamarts, le streaming et l'exposition API, avec une identité visuelle EFREI.

1. Résumé exécutif

- Architecture data Paris multi-sources, orientée métier et démonstration.
- Bronze/Silver/Gold avec HDFS, Spark et Polars pour la transformation.
- Datamarts relationnels dans PostgreSQL et événements temps réel dans Cassandra.
- API FastAPI documentée, sécurisable et prête pour une exposition contrôlée.
- Frontend moderne, responsive et orienté pilotage de soutenance.

2. Objectif du projet

L'objectif est de livrer un socle data universellement accessible, capable de rassembler des jeux de données urbains, culturels, sociaux et de mobilité autour des arrondissements parisiens. La solution doit démontrer la conception d'une base relationnelle, d'une base NoSQL, d'un lac de données, d'infrastructures scalables et d'une API documentée.

3. Branding EFREI et rendu

Identité visuelle	Couleurs bleu marine et rouge institutionnel, logo EFREI en couverture.
Typographie	Arial pour garantir un rendu stable sur Windows et une bonne lisibilité.
Style	Grands espaces, sections structurées, tableaux et encadrés de
Usage	Rapport prêt à être joint au dossier de soutenance et transmis en PDF.

4. Jeux de données intégrés

Le projet s'appuie sur les sources identifiées sur la machine et structurées dans un catalogue interne. Les sources Paris Open Data alimentent les indicateurs opérationnels, tandis que data.gouv.fr complète la couche culture et santé.

Espaces verts	Paris Open Data
Stationnement emprises	Paris Open Data
Belib	Paris Open Data
Velib stations	Paris Open Data
Sanisettes	Paris Open Data
Aménagements cyclables	Paris Open Data
Chantiers perturbants	Paris Open Data

Écoles / collèges	Paris Open Data
Marchés découverts	Paris Open Data
Loisirs / que faire à Paris	Paris Open Data
Logements sociaux	Paris Open Data
Immeubles protégés	data.gouv.fr
Musées de France	data.gouv.fr
Hôpitaux franciliens	data.gouv.fr
Médecins HAS	data.gouv.fr

5. Architecture technique

Bronze	Snapshots bruts par source dans HDFS avec métadonnées d'ingestion.
Silver	Nettoyage, typage, normalisation et enrichissement des colonnes communes.
Gold	Datamarts arrondissements dans PostgreSQL et exports parquet sur HDFS.
Streaming	Kafka alimente Spark Structured Streaming puis HDFS et Cassandra.
API	FastAPI expose le catalogue, la supervision et les données métier.
Frontend	Dashboard immersif avec KPI, pipeline, catalogue et événements.

6. Pipelines de données

- Le job Bronze télécharge les exports ou métadonnées et les stocke avec une date de snapshot.
- Le job Silver applique la même logique de normalisation à toutes les sources intégrées.
- Le job Gold agrège les signaux par arrondissement, calcule des indices et charge PostgreSQL.
- Le streaming Kafka est persisté simultanément dans HDFS et Cassandra pour la consultation rapide.

7. API documentée

L'API expose des routes groupées dans Swagger et ReDoc avec une description par tag. Les endpoints principaux permettent d'interroger le catalogue, le datamart Gold, le dernier run pipeline et les derniers événements temps réel.

GET /	Point d'entrée simple avec liens vers la documentation.
GET /health	Contrôle de disponibilité.
GET /catalog/sources	Catalogue des sources intégrées.
GET /datamarts/dashboard	Vue KPI arrondissement.
GET /datamarts/timeline	Tendance mensuelle des volumes.
GET /pipeline/latest	Dernier run de pipeline.
GET /events/recent	Événements récents depuis Cassandra.

8. Frontend de démonstration

- Hero visuel fort et hiérarchie claire pour la maintenance.
- Filtres de catalogue, cartes KPI et mini-dashboard arrondissement.

- Graphique SVG sans dépendance lourde pour la charge par mois.
- Bloc supervision, événements temps réel et token local optionnel.
- Responsive design adapté à un écran projeté ou à un laptop.

9. Production et robustesse

Docker Compose	Restart policies, healthchecks et séparation des services.
Sécurité	Token API optionnel via variable d'environnement.
Observabilité	État du pipeline, endpoints health et retour d'erreur lisible.
Déploiement	Composants prêts à être reconstruits sur une machine propre.
Livrable PDF	Rapport généré automatiquement avec FPDF2 et branding EFREI.

10. Correspondance avec le bloc RNCP40875

C1.1	Modèle relationnel PostgreSQL normalisé, datamarts et intégrité.
C1.2	Cassandra pour les événements temps réel et les objets semi-structurés.
C1.3	Bronze/Silver/Gold sur HDFS, permissions, zones et séparation des usages.
C1.4	Spark scalable, HDFS partitionné, restart policies et healthchecks Docker.
C2.1	API FastAPI documentée avec OpenAPI, Swagger, ReDoc et clé optionnelle.
C2.2	Streaming Kafka -> Spark Structured Streaming -> HDFS + Cassandra.
C2.3	Polars normalise les sources Paris/data.gouv vers une structure commune.
C2.4	Pipelines optimisés, indicateurs de suivi et résilience de bout en bout.

11. Conclusion

La solution réunit la logique attendue pour une évaluation complète : architecture de stockage, traitement distribué, streaming, API documentée, rapport détaillé et présentation visuelle sérieuse. Le socle peut servir de base de soutenance, de démonstration ou de reprise en environnement de production.