

**REPUBLIQUE FRANCAISE**

Donnees ouvertes · Ville de Paris

# Urban Data Explorer

Observatoire socio-urbain de Paris

---

## Rapport de soutenance

RNCP40875 · Bloc 1 · Expert en Ingenierie des Donnees

Certificateur : Efrei · Paris Pantheon-Assas Universite

Binome : Adam Beloucif & Emilien Morice

Soutenance 2026

## 1 Le projet en quelques mots

Imaginez un decideur de la Ville de Paris qui veut comparer deux arrondissements : ou les loyers grimpent, ou il manque de logements sociaux, ou la qualite de vie est la meilleure. Aujourd'hui, ces reponses sont eparpillees dans des dizaines de jeux de donnees ouvertes, dans des formats differents. Notre projet rassemble ces donnees au meme endroit et les rend lisibles sur une carte interactive.

Urban Data Explorer est un observatoire socio-urbain de Paris. On y explore, arrondissement par arrondissement, le marche immobilier, le logement social, les revenus, le cadre de vie et l'environnement. Derriere cette carte simple se cache une chaine de donnees complete, que nous presentons dans ce rapport : c'est elle qui valide les competences du Bloc 1.

*Notre objectif : transformer des donnees publiques dispersees en un outil d'aide a la decision clair, fiable et agreable a utiliser.*

**24**

sources de donnees

**8**

familles de donnees

**20**

arrondissements

**5**

niveaux de zoom

## 2 Notre demarche et l'organisation du binome

Le projet a ete mene en binome, en mode collectif. Nous avons travaille de maniere iterative : d'abord faire circuler la donnee de bout en bout (meme simplement), puis enrichir chaque maillon. Cette approche nous a permis d'avoir tres tot une demonstration qui fonctionne, puis de l'ameliorer.

- **Repartition** : un focus partage entre la chaine de donnees (ingestion, bases, API) et la restitution (carte, interface, experience utilisateur), avec des points de synchronisation reguliers.
- **Methode** : versionnage Git, decoupage en taches, et un mode local-first pour que chacun puisse faire tourner le projet sans dependre d'une infrastructure lourde.
- **Fil rouge** : rester guides par le besoin metier (comparer des arrondissements) plutot que par la technique pour la technique.

### 3 L'architecture en un coup d'oeil

On peut resumer le projet comme le voyage d'une donnee, du fichier brut jusqu'a la carte. Ce voyage suit trois etapes (le pattern medaillon Bronze, Silver, Gold) :

- **Bronze** : on recupere les fichiers Open Data tels quels et on les range proprement.
- **Silver** : on nettoie, on harmonise les codes d'arrondissement et on place chaque point sur la carte.
- **Gold** : on calcule les indicateurs prêts a afficher et on les charge dans la base d'analyse.

Ensuite, une API met ces donnees a disposition, et l'interface web les affiche sous forme de carte et de graphiques. En parallele, un flux temps reel alimente l'observatoire en evenements (disponibilite Velib, chantiers). Le tout peut tourner sur un simple poste, ou en mode distribue avec Docker.

#### LES BRIQUES TECHNIQUES (LANGAGE CLAIR)

- **Traitement** : Polars, un moteur de calcul tres rapide, pour transformer les donnees.
- **Bases de donnees** : PostgreSQL pour l'analyse structuree, Cassandra pour les flux d'evenements.
- **Lac de donnees** : des fichiers Parquet compresses, organises par etape.
- **API & interface** : FastAPI cote serveur, React et cartographie cote ecran (fond de plan IGN).

### 4 Les donnees : richesse, reel et qualite

Nous integrons 24 sources, regroupees en 8 familles : mobilite, education, logement, culture, sante, espaces verts, services publics et pression urbaine. Deux sources de reference nationales alimentent le coeur logement avec des valeurs reelles :

- **DVF (data.gouv.fr)** : les vraies transactions immobilieres 2023 de Paris donnent le prix au m2 median et le volume de ventes par arrondissement.
- **INSEE Filosofi 2020** : le vrai revenu median des menages par quartier IRIS, agrege par arrondissement.
- **Geocodage hors ligne** : on retrouve l'arrondissement a partir des coordonnees, sans service externe ; l'API nationale d'adresses sert de filet de securite.
- **Tracabilite qualite** : chaque donnee porte une etiquette (reelle ou de reference, et mode de rattachement).

## 5 Ce que nous demontrons (competences du Bloc 1)

Le Bloc 1 evalue la capacite a construire une architecture de stockage et de traitement. Voici, en langage clair, ce que le projet met en oeuvre pour chaque competence.

### STOCKER LA DONNEE

- **C1.1 · Base relationnelle** : un modele en etoile dans PostgreSQL, avec des regles d'integrite (cles, contraintes) et des index pour aller vite. Nous l'avons mis a l'epreuve par des tests de charge.
- **C1.2 · Base NoSQL** : Cassandra accueille les evenements en continu ; ils sont tries du plus recent au plus ancien et s'effacent automatiquement au bout de 7 jours.
- **C1.3 · Lac de donnees** : les fichiers Parquet organisent les donnees variees par etape, de maniere performante et economique.
- **C1.4 · Scalabilite & resilience** : Docker Compose avec redemarrage automatique, sondes de sante (postgres, cassandra, api), demarrage ordonne et volumes persistants ; le mode local-first garantit la continuite meme sans cluster.


### TRAITER ET EXPOSER LA DONNEE

- **C2.1 · API** : FastAPI accessible et documentee (/docs), filtrable (par arrondissement, score), avec authentication JWT (roles viewer/admin) et quotas par IP (anonyme 120, connecte 600 req/min).
- **C2.2 · Streaming** : Kafka collecte les flux urbains en temps reel et les transmet a la base d'evenements.
- **C2.3 · Transformation** : Polars fusionne des sources heterogenes et les structure pour l'analyse.
- **C2.4 · Optimisation** : formats compressees et index garantissent un acces rapide, mesure par nos tests.


## 6 La demonstration : l'interface

La partie visible du projet est un tableau de bord cartographique qui adopte les codes du Systeme de Design de l'Etat (DSFR) : police Marianne, bleu France, rouge Marianne et le bloc Republique Francaise. Un choix assume, qui inscrit l'outil dans une identite institutionnelle credible.

- **Carte officielle** : fond de plan IGN, avec un zoom progressif de la ville jusqu'au batiment.
- **Lecture immediate** : une coloration de la carte par indicateur, avec une legende dynamique.
- **Comparaison** : deux arrondissements affiches cote a cote pour trancher d'un coup d'oeil.
- **Soin de l'accessibilite** : contrastes conformes, theme clair et sombre, navigation au clavier.



Theme clair · fond de plan IGN



Theme sombre · accessibilite WCAG AA

## COTE SERVEUR : L'API REST DOCUMENTEE

Chaque jeu de données est exposé par une API FastAPI qui se documente toute seule. Depuis le navigateur, on visualise et on teste en direct toutes les routes : état du projet, catalogue des sources, indicateurs, contours géographiques et flux d'événements. L'API est protégée par une authentification JWT (roles viewer/admin) et un quota de requêtes par IP.

## Urban Data Explorer 4.0.0 OAS 3.1

/openapi.json

API backend pour le dashboard Paris : logement, mobilité, éducation, culture, espaces verts.

**health** État local du projet.

GET

/health

Health

GET

/

Root

**catalog** Catalogue de sources intégrées.

GET

/catalog/sources

Sources

**datamarts** Données de synthèse et carte.

GET

/datamarts/dashboard

Dashboard

GET

/datamarts/overview

Overview

GET

/datamarts/timeline

Timeline

GET

/datamarts/geojson/{level}

Get Geojson

**pipeline** Dernier run du pipeline.

GET

/pipeline/latest

Latest Run

**events** Derniers événements simulés.

Documentation interactive /docs · routeurs health, catalog, datamarts, pipeline, events, repo

## 7 Resultats et validation

Pour prouver que la base relationnelle tient la charge, nous avons simule plusieurs utilisateurs lancant des requetes d'analyse en meme temps. Les resultats confirment la solidite du modele :

| Ce que nous avons mesure               | Resultat                           |
|----------------------------------------|------------------------------------|
| Requetes traitees sans erreur          | 500 sur 500                        |
| Vitesse de traitement                  | environ 1 190 requetes par seconde |
| Temps de reponse moyen                 | 1,80 ms                            |
| Temps de reponse au pire des cas (p95) | 3,50 ms                            |
| Regles d'integrite verifiees           | 3 sur 3 validees                   |

Autrement dit : meme sollicitee par plusieurs utilisateurs, la base repond en quelques millisecondes et n'accepte aucune donnee incoherente. C'est exactement ce qu'attend une gouvernance de donnees.

## 8 Bilan : couverture de la grille RNCP40875

| Competence | Comment le projet la valide                                    |
|------------|----------------------------------------------------------------|
| C1.1       | Modele en etoile PostgreSQL + tests de charge reussis          |
| C1.2       | Cassandra pour les evenements (tri par date, purge 7 jours)    |
| C1.3       | Lac de donnees Bronze/Silver/Gold en Parquet                   |
| C1.4       | Docker multi-services + mode local-first resilient             |
| C2.1       | API FastAPI documentee + auth JWT (roles) + quotas par IP      |
| C2.2       | Streaming Kafka temps reel vers Cassandra                      |
| C2.3       | Fusion de sources reelles (DVF + INSEE Filosofi) avec Polars   |
| C2.4       | Parquet + index + drapeau qualite data_source (reel/reference) |

## 9 Conclusion et perspectives

Urban Data Explorer demontre une chaine de donnees complete et coherente, du fichier brut jusqu'a la carte interactive, en couvrant l'ensemble des competences C1.1 a C2.4. Le projet est a la fois robuste (il tourne en local comme en distribue) et soigne (standards de l'Etat, accessibilite).

- **Pour aller plus loin** : brancher les sources reelles de prix (DVF) et de revenus (INSEE), activer l'authentification de l'API, et envisager un deploiement dans le cloud avec des alertes sur les flux temps reel.

*Merci de votre attention. Nous restons disponibles pour repondre a vos questions et faire une demonstration en direct de l'outil.*